

INTELEKTUALIOSIOS SISTEMOS

Magistrantūros studijos

EGZAMINO ATASKAITA

KRŪTIES NAVIKO POŽYMIŲ KLASIFIKAVIMAS

Sprendimo palaikymo prototipas pagal ląstelių branduolių požymius

Duomenys: UCI Breast Cancer Wisconsin (Diagnostic), WDBC

Kamil Skaskevič, EKSfm-26

2026 m. rugsėjis

Turinys

1. Praktinė problema, techninis uždavinys ir sprendimo vertė	3
2. Duomenų rinkinys, įvestis, išvestis ir duomenų paruošimas	3
3. Apskaitos ir intelektualieji metodai bei literatūros pagrindimas.....	4
4. Modelių formulės, mokymas ir sąsaja su kodu	4
4.1 Logistinė regresija ir polinominis SVM.....	4
4.2 Daugiasluoksnis perceptronas	4
4.3 RBF tinklas	5
4.4 Ansamblis M4	5
5. Eksperimentų protokolai, metrikos ir patikimumo patikros	5
6. Rezultatai ir hipotezių vertinimas	6
7. Abiliacijos ir tobulinimo bandymai.....	9
8. Atsparumo bandymas	10
9. Klaidų analizė, sprendimo ribos ir praktinis tinkamumas.....	10
10. Paleidimas ir atkuriamumas	11
11. AI naudojimo žurnalas	12
12. Išvados	12
Literatūra	13

1. Praktinė problema, techninis uždavinys ir sprendimo vertė

Plonosios adatos aspiracinės biopsijos metu iš ląstelių branduolių jau būna apskaičiuoti geometriniai požymiai. Gydytojui reikia ne naujos automatinės diagnozės, o pagalbos nuspręsti, ar atvejį verta laikyti piktybiniu ir siųsti tolesniam tyrimui. Praleistas piktybinis atvejis (klaidingai neigiamas) šiame darbe laikomas penkis kartus brangesniu už perteklinį gerybinio atvejo pažymėjimą (klaidingai teigiamą). Santykis 5:1 yra darbo prielaida, ne klinikinis tarifas.

Techninis uždavinys yra dvejetainis klasifikavimas. Įvestis yra 30 požymių vektorius be paciento identifikatoriaus. Išvestis yra piktybinumo tikimybė, slenkstis ir sprendimas M arba B. Sprendimas nėra klinikinė diagnozė. Naudinga tai, kad tie patys duomenys ir ta pati metrika leidžia palyginti tiesinį modelį, branduolio metodą, neuronų tinklą ir jų junginį, o slenkstį parinkti pagal klaidų kainą, ne pagal bendrą tikslumą.

Pagrindinis tiriamas metodas yra modifikuotas ansamblis M4. Jis jungia polinominio branduolio atraminių vektorių mašiną, daugiasluoksnį perceptroną ir logistinę regresiją. Narių tikimybės kalibruojamos atskirai ir svertinai vidurkinamos. Stipriai koreliuoti požymiai mokymo skaidinyje šalinami, kai absoliuti Pearsono koreliacija didesnė už 0,95. Hipotezė H1, užrašyta prieš galutinį testą: taške t_{se98} specifiškumas $Sp(M4)$ turi būti bent 0,03 didesnis už $Sp(B1)$, o plotas po ROC kreive neturi sumažėti daugiau kaip 0,005. H2: M4 Brier įvertis ne daugiau kaip 0,01 didesnis už B1, o kalibracijos nuolydis yra nuo 0,8 iki 1,25.

2. Duomenų rinkinys, įvestis, išvestis ir duomenų paruošimas

Naudojamas viešas UCI rinkinys Breast Cancer Wisconsin (Diagnostic), identifikatorius 17, DOI 10.24432/C5DW2B. Jį sudaro 569 atvejai: 212 piktybinių ir 357 gerybiniai, 30 požymių, trūkstančių reikšmių nėra. Identifikatorius pašalinamas faile `load_wdbc.m` prieš bet kokią skaidymą. Neigiama požymio reikšmė sustabdo skaičiavimą. Nuliai požymiuose `concavity` ir `concave_points` paliekami, nes jie yra oficialiame faile ir nėra trūkstamos reikšmės.

Skaidymas fiksuotas sėkla `rng(42)`. Mokymui skiriama 455 atvejų: 170 piktybinių ir 285 gerybiniai. Testui skiriama 114 atvejų: 42 piktybiniai ir 72 gerybiniai. Indeksai nesikerta ir padengia visus 569 atvejus. Tai patikrinta funkcija `test_result_consistency`. MATLAB funkcija `cvpartition` su `HoldOut` 0,20 šiai klasių sudėčiai suapvalina iki 113 testavimo atvejų (71 gerybinis). Plano dydis 114 įrašytas `make_split.m` dar prieš mokymą, ne pagal testo metrikas.

Standartizacija $z = (x - \text{vidurkis}) / \text{standartinis nuokrypis}$ skaičiuojama tik iš to mokymo poaibio, kuris tuo metu mokomas. `fit_scaler.m` atmeta visą 569 eilučių matricą. `apply_scaler.m` vidurkio iš naujo neskaičiuoja. M4 požymių atranka taip pat vyksta tik mokymo skaidinyje. Testavimo aibė nenaudojama standartizacijai, atrankai, hiperparametrams, kalibracijai, svoriams ir slenkščiai.

Elementas	Reikšmė	Prasmė
Įvestis	30 požymių	vienas atvejis be identifikatoriaus
<code>p_malignant</code>	tikimybė (0, 1)	piktybinumo tikimybė
slenkstis <code>t</code>	iš OOF	sprendimas M, kai $p \geq t$
<code>margin_flag</code>	$ p - t < 0,10$	atvejis arti slenkščio, skirtas peržiūrai
<code>ood_flag</code>	už mokymo <code>min-max</code>	požymis išeina už mokymo ribų

1 lentelė. Prototipo įvestis ir išvestis (`predict_case.m`).

3. Atskaitos ir intelektualieji metodai bei literatūros pagrindimas

B0 yra daugumos klasės atskaita. Klasės sprendimas visada yra gerybinis, nes mokymo aibėje gerybinių daugiau. Tikimybinė išvestis yra $p(M) = 0$. Faile `train_majority.m` papildomai saugomas $priorM = 170/455$, bet `predict_proba` jo nenaudoja. Dėl to Brier įvertis teste yra $42/114 = 0,368$, o ne apie 0,233, kuris būtų gautas su pastovia klasės dažnio tikimybe. Realizacija nekeista.

B1 yra L2 reguliarizuota logistinė regresija su klasių svoriais pagal kainą 5:1. Tikimybė yra sigmoidė nuo tiesinio balo. Hiperparametras λ parinktas pagal vidutinį OOF ROC-AUC. Užšaldyta reikšmė yra 0,1 (`logreg.mat`).

M1 yra atraminė vektorių mašina su RBF branduoliu. Užšaldyti parametrai yra $C = 0,3$ ir branduolio mastelis $s = 12$. Jie įrašyti faile `svm_rbf.mat`. M2 yra daugiasluoksnis perceptronas: vienas paslėptas sluoksnis, $H = 5$, `patternnet` reguliarizacijos dalis 0,3, penkios pradinės reikšmės. M3 yra RBF tinklas. Užšaldyti parametrai faile `rbfnet.mat` yra $J = 10$ centrų, $\kappa = 2$ ir $\lambda = 0,001$. Centrai randami k vidurkių metodu, išėjimo svoriai skaičiuojami uždara ridge formule.

M4 yra šio darbo modifikacija. Rasool ir kt. (2022) WDBC rinkinyje lygino logistinę regresiją, k artimiausių kaimynų metodą, ansamblį bei tiesinį ir polinominį SVM ir nagrinėjo požymių Pearsono koreliaciją. Šiame projekte stipriai koreliuotų požymių šalinimo riba yra 0,95. Ji užrašyta darbo plane kaip projekto taisyklė. Straipsnis cituojamas dėl krypties, ne kaip pažodinę procedūros kopiją. Al Reshan ir kt. (2023) cituojami kaip ansamblių krypties šaltinis. M4 svorių vidurkis yra šio projekto OOF procedūra ir nėra tų autorių metodo kopija. Nariai, svoriai ir atranka aprašyti 4 skyriuje.

4. Modelių formulės, mokymas ir sąsaja su kodu

4.1 Logistinė regresija ir polinominis SVM

B1 tikimybė yra $p = 1 / (1 + \exp(-(w'z + b)))$. Ji realizuota `train_logreg.m` funkcija `fitlinear`. Jei modelis turi Platt parametrus, `predict_proba.m` tikimybę pakeičia sigmoide nuo to paties tiesinio balo.

M4 polinominio nario sprendimo funkcija, susieta su `svm_poly_score.m` 13–14 eilutėmis, yra $f(z) = \sum \alpha_i * y_i * (z' z_i + r)^d + b$. Kode z ir atraminiai vektoriai pirma dalijami iš mastelio s , todėl tai sutampa su $(\gamma z' z_i + r)^d$, kur $r = 1$ ir $\gamma = 1/s^2$. M4 nariui $d = 3$, $s = 4$, $C = 1$. Atskiras polinominis modelis `svm_poly.mat` turi $d = 2$. Tai ne tas pats objektas.

4.2 Daugiasluoksnis perceptronas

Architektūra yra $30 \rightarrow H \rightarrow 1$, $H = 5$. Paslėptas sluoksnis: $h = \tanh(W1 z + b1)$. Išėjimas: $p = 1 / (1 + \exp(-(w2' h + b2)))$. Produkcinis mokymas yra `train_mlp.m`, `patternnet` ir `trainscg`. Penkių tinklų tikimybės vidurkinamos `predict_proba.m` funkcijoje `mlp_p`, 86–94 eilutės.

Rankinis failas `mlp_backprop_manual.m` yra mokomoji realizacija, nenaudojama pagrindinei lentelei. Jo nuostolis yra vidutinė dvejetainė kryžminė entropija plius $(\lambda/2)$ kartų svorių kvadratų suma. Išvestys: $\delta_2 = p - y$ (22 eilutė) ir $\delta_1 = (1 - h.^2) .* (w2 * \delta_2)$ (23 eilutė). Svoriai atnaujinami 24–27 eilutėse. `patternnet` `performParam.regularization` yra kita taisyklė: $(1 - r) * \text{kryžminė entropija} + r * \text{vidutinis svorių kvadratas}$, kur r yra nuo 0 iki 1. Todėl $\lambda = 0,3$ produkciniam tinkle nėra tas pats koeficientas kaip rankiniame L2 naryje.

Formulė	Kodas	Vieta
$h = \tanh(W1 \cdot z + b1)$	$a1 = W1 \cdot Z' + b1; h = \tanh(a1)$	mlp_backprop_manual.m 17–18
$p = \text{sigma}(w2' \cdot h + b2)$	$a2 = w2' \cdot h + b2; p1 = 1./(1+\exp(-a2))$	mlp_backprop_manual.m 19–20
$\text{delta2} = p - y$	$\text{delta2} = p1 - y'$	mlp_backprop_manual.m 22
delta1	$(1-h.^2).*(w2*\text{delta2})$	mlp_backprop_manual.m 23
W1 ir w2 žingsnis su L2	$W1 = W1 - (\text{eta}/n).*(\text{delta1} \cdot Z) - \text{eta} \cdot \text{lambda} \cdot W1$	mlp_backprop_manual.m 24–26
Produkcinis mokymas	patternnet(H,'trainscg'); train(...)	train_mlp.m 22–37

2 lentelė. MLP formulės ir kodo eilutės (mokomoji realizacija).

4.3 RBF tinklas

M3 centrai randami k vidurkių metodu tik iš mokymo matricos, train_rbfnet.m 21 eilutė. Plotis $s_j = \text{kappa} \cdot \text{vidutinis atstumas iki dviejų artimiausių centrų}$, 30 eilutė. Bazinė funkcija $\text{phi}_j = \exp(-\|z - c_j\|^2 / (2 s_j^2))$ yra 53–55 eilutėse. Svoriai $w = (\text{Phi1}' \text{Phi1} + \text{lambda} \cdot \text{I})^{(-1)} \text{Phi1}' y$ tilde, 35–36 eilutės. Tikimybė skaičiuojama predict_proba.m 64–66 eilutėse. Dabartiniame rbfnet.mat yra $J = 10$, $\text{kappa} = 2$, $\text{lambda} = 0,001$.

4.4 Ansamblis M4

$$p_4(z) = (w_1 p_{\text{svm}}(z) + w_2 p_{\text{mlp}}(z) + w_3 p_{\text{lr}}(z)) / (w_1 + w_2 + w_3)$$

p_{svm} , p_{mlp} ir p_{lr} yra atskirai kalibruotos narių tikimybės. Kalibracija yra Platt sigmoidė $p = 1 / (1 + \exp(A \cdot f + B))$. A ir B mokomi tik iš to nario OOF balų. Testavimo balai kalibracijai nenaudojami. Užšaldytos reikšmės: polinominis SVM $A = -2,922$, $B = 0,702$; MLP $A = -1,094$, $B = 0,952$; logistinė regresija $A = -2,553$, $B = 1,939$.

Svoriai renkami tinkleliu 0, 0,1, ..., 1 ir normalizuojami. Tinklas ieško mažiausios OOF empirinės kainos $EC = 5 \cdot FN + 1 \cdot FP$ tarp variantų, kurių OOF jautrumas yra bent 0,98. Testas svoriams nenaudotas. Gautas svoris yra 0,583 polinominiam SVM, 0,333 daugiasluoksniui perceptronui ir 0,083 logistinei regresijai. Lygių svorių variantas 1/3, 1/3, 1/3 paliktas abliacijai. Slenkstis t_se98 yra didžiausias slenkstis, kurio OOF jautrumas yra bent 0,98. M4 jis lygus 0,33. OOF riba buvo pasiekta (se_target_met = 1).

Požymių atranka: mokymo matricoje požymių pora, kurios absoliuti Pearsono koreliacija didesnė už 0,95, netenka to nario, kurio absoliuti koreliacija su klase mažesnė. Lygios koreliacijos atveju šalinamas didesnis indeksas. Galutinis M4 sąrašas, 23 požymiai: texture_mean, smoothness_mean, compactness_mean, concavity_mean, concave_points_mean, symmetry_mean, fractal_dimension_mean, radius_se, texture_se, smoothness_se, compactness_se, concavity_se, concave_points_se, symmetry_se, fractal_dimension_se, texture_worst, perimeter_worst, smoothness_worst, compactness_worst, concavity_worst, concave_points_worst, symmetry_worst, fractal_dimension_worst. Pašalinti radius, perimeter ir area vidurkiai bei dalis jų išvestinių, nes jos stipriai koreliuoja.

5. Eksperimentų protokolai, metrikos ir patikimumo patikros

Visi modeliai lyginami tame pačiame 455/114 skaidinyje ir tame pačiame taške t_se98. Hiperparametrai parenkami pagal vidutinį OOF ROC-AUC per 5 kartus po 5 skaidinius. Jei vidutinis AUC nuo geriausio skiriasi mažiau kaip 0,002, imama paprastesnė konfigūracija. OOF balai per kartojimus vidurkinami. Tai nėra testavimo aibės naudojimas.

Jautrumas $Se = TP / (TP + FN)$ rodo, kokią piktybinių atvejų dalį modelis pažymi kaip piktybinę. Specifiškumas $Sp = TN / (TN + FP)$ rodo, kokią gerybinių atvejų dalį modelis palieka gerybine. ROC-AUC yra tikimybė, kad atsitiktinio piktybinio atvejo balas bus didesnis už atsitiktinio gerybinio. Jis nepasako, kas vyksta prie vieno aukšto jautrumo slenksčio. Brier įvertis yra vidutinis $(p - y)^2$. Mažesnis Brier reiškia tikslesnes tikimybes, ne būtinai geresnį sprendimą prie 5:1 kainos. Pasikliautiniai intervalai jautrumui, specifiškumui, AUC ir Brier yra porinis bootstrap, 2000 pakartojimų. AUC skirtumui naudojamas DeLong testas.

Patikros, kurias galima pakartoti: `test_no_leakage.m` tikrina, kad standartizatoriaus vidurkis sutampa su mokymo vidurkiu ir kad OOF eilutė neįeina į tą foldą mokių matricą. `test_result_consistency.m` tikrina 455/114 skaidinį, kiekvienos rezultatų eilutės Se , Sp ir $n = 114$ bei tai, kad A5 all30 sutampa su M1. Eksperimento identifikatorius yra WDBC-seed42-n569-train455-test114-M42B72.

Modelis	Failas	Užšaldyta reikšmė
B1	logreg.mat	$\lambda = 0,1$
M1	svm_rbf.mat	$C = 0,3$, $s = 12$
M2	mlp.mat	$H = 5$, regularization = 0,3, 5 sėklos
M3	rbfnet.mat	$J = 10$, $\kappa = 2$, $\lambda = 0,001$
M4 SVM narys	ensemble.mat	$d = 3$, $s = 4$, $C = 1$
M4 svoriai	ensemble.mat	0,583; 0,333; 0,083

3 lentelė. Užšaldyti hiperparametrai iš modelių failų. Testas paieškai nenaudotas.

6. Rezultatai ir hipotezių vertinimas

4 lentelė yra galutinis testas, 114 atvejų, taškas t_{se98} . Skaičiai sutampa su `results_test.csv` ir `main_results.csv`. Stulpelis FN/42 yra klaidingai neigiamų dalis tarp piktybinių, ne tarp visų 114 atvejų.

Modelis	t	Se	Sp	FN	FN/42	FP	AUC	BS	EC
B0	0,50	0,000	1,000	42	1,000	0	0,500	0,368	210
B1	0,22	0,952	0,944	2	0,048	4	0,983	0,035	14
M1	0,18	0,952	0,944	2	0,048	4	0,981	0,038	14
M2	0,34	0,929	0,972	3	0,071	2	0,986	0,034	17
M3	0,22	0,929	0,917	3	0,071	6	0,976	0,045	21
M4	0,33	0,929	0,944	3	0,071	4	0,977	0,047	19


4 lentelė. Testas $n = 114$, taškas t_{se98} .

Pagal empirinę kainą $EC = 5 \cdot FN + FP$ mažiausią kainą teste turi B1 ir M1, po 14. M4 kaina yra 19, nes atsiranda trečias klaidingai neigiamas atvejis, o klaidingai teigiamų lieka keturi. M2 turi aukščiausią AUC, 0,986, ir didžiausią specifiškumą, 0,972, bet jautrumas 0,929 ir kaina 17. Didelis AUC savaime nepasirenka metodo, kai vienas praleistas piktybinis kainuoja penkis kartus daugiau už vieną klaidingą aliarmą.


H1 nepatvirtinta. $Sp(M4) - Sp(B1) = 0$. Porinio bootstrap 95 % intervalas yra nuo -0,042 iki 0,040, taigi apatinė riba nėra teigiama. $AUC(M4) - AUC(B1) = -0,0056$. DeLong 95 % intervalo apačia yra -0,020, ji žemesnė už -0,005. H2 nepatvirtinta. Brier skirtumas yra 0,012, didesnis už leistiną 0,01. Kalibracijos nuolydis yra 0,711 ir nepatenka į intervalą nuo 0,8 iki 1,25. Sąlygos po testo nekeistos. Prototipas pagal išankstinę taisyklę yra B1.

1 paveikslas rodo, kad visų modelių ROC kreivės yra viršutiniame kairiajame kampe, AUC didesnis už 0,97. Priartintame lange darbo taškai išsiskiria, bet M4 taškas nėra dešiniau ir aukščiau už B1 taip, kad specifiškumas išaugtų 0,03. 2 paveikslas, penki kvantilių režiai, rodo, kad B1 ir M4


tikimybės nėra chaotiškos, tačiau M4 nuolydis 0,711 vis tiek neišpildo H2. 3 ir 4 paveikslai rodo painingą: B1 turi 2 FN iš 42 piktybinių (4,8 %), M4 turi 3 FN (7,1 %). Viso testo atžvilgiu tai yra 1,8 % ir 2,6 %, bet klinikiu požiūriu svarbesnė dalis yra iš piktybinių. 5 paveikslas rodo empirinę kainą kaip slenksčio funkciją. B1 darbo taškas $t = 0,22$ ir M4 darbo taškas $t = 0,33$ pažymėti ant kreivių. Jie parinkti pagal OOF jautrumo taisyklę, ne pagal mažiausią testo kreivės tašką.




1 paveikslas. ROC kreivės testavimo aibėje ir priartintas kampas ties t_{se98} .




2 paveikslas. Tikimybių kalibracija penkiais kvantilių rėžiais, B1, M1 ir M4.



3 paveikslas. B1 painiavos matrica taške $t_{se98} = 0,22$.



4 paveikslas. M4 painiavos matrica taške $t_{se98} = 0,33$.



7. Abliacijos ir tobulinimo bandymai

Abliacijos atliktos po to, kai pagrindinis M4 jau buvo užšaldytas. Jos nekeitė H1. Variantai buvo mokomi tik mokymo duomenyse. Testas naudotas tik galutiniam suskaičiavimui, ne svorių ar slenksčio paieškai. Todėl šios lentelės nėra naujas nepriklausomas patvirtinimas. Jos rodo, kas būtų buvę, jei atranka ar svoriai būtų buvę kitokie.

ID	Variantas	Se	Sp	FN	FP	AUC
A0	daugumos klasė	0,000	1,000	42	0	0,500
A5	10 vidurkio požymių	0,929	0,847	3	11	0,968
A5	10 didžiausių požymių	0,952	0,944	2	4	0,978
A5	visi 30, tai yra M1	0,952	0,944	2	4	0,981
A5	M4 su atranka	0,929	0,944	3	4	0,977
A5	M4 be atrankos	0,929	0,958	3	3	0,986
A9	M4 lygūs svoriai	0,929	0,958	3	3	0,980
A9	M4 OOF svoriai	0,929	0,944	3	4	0,977

5 lentelė. Abliacija tame pačiame 114 atvejų teste (ablation.csv).

Visi 30 požymių duoda tą patį testą kaip M1: FN = 2, FP = 4, specifiškumas 0,944, AUC 0,981. Dešimt vidurkio požymių specifiškumą sumažina iki 0,847 (FP = 11). Dešimt didžiausių požymių išlaiko tą patį FN ir FP skaičių kaip M1, bet AUC yra 0,978, šiek tiek mažesnis. Praktinė išvada šiai imčiai: požymių grupės pasirinkimas keičia klaidingai teigiamų skaičių, o vien aukštas AUC neatstoja kainos prie slenksčio.

Ką bandymai patvirtina: pašalinus koreliuotus požymius, M4 specifiškumas teste nepadidėjo. Be atrankos Sp = 0,958 ir AUC = 0,986, su atranka Sp = 0,944 ir AUC = 0,977. Lygūs svoriai teste taip pat duoda Sp = 0,958, o OOF kaina parinkti svoriai duoda Sp = 0,944. Tai neigiamas rezultatas ir jis paliekamas. Tikėtinas paaiškinimas, ne įrodymas, yra tas, kad 455 atvejų OOF kaina yra triukšminga ir svoris 0,083 logistinei regresijai per stipriai sumažina tiesinį narį. Ko šiuo eksperimentu negalima teigti: kad atranka apskritai nenaudinga kitai imčiai arba kad Rasool taisyklė WDBC rinkinyje neveikia. Testas jau buvo matytas, kai šios abiliacijos buvo aiškinamos, todėl jos neperkeliamos į naują H1.

8. Atsparumo bandymas

Triukšmas pridedamas prie neapdorotų testavimo požymių: $x_{\text{triukšmas}} = x + \sigma * s_{\text{mok}}$. s_{mok} yra kiekvieno požymio standartinis nuokrypis, skaičiuotas tik mokymo aibėje. Modelis, Platt parametrai ir slenkstis nekeičiami. Lygiai $\sigma = 0,10$ ir $0,25$, penki kartojimai, sėklos išvestos iš 42. FN ir FP lentelėje yra tų kartojimų vidurkiai, ne vieno atsitiktinio bandymo sveikieji skaičiai. Atskirai išbandytas 5 % ir 10 % langelių pašalinimas su mokymo mediana. Tas pildymas naudojamas tik atsparumo faile, ne pagrindinėje grandinėje.

Modelis	sigma	Se	Sp	AUC	BS	FN	FP
B1	0	0,952	0,944	0,983	0,035	2,0	4,0
B1	0,10	0,952	0,944	0,983	0,036	2,0	4,0
B1	0,25	0,943	0,931	0,985	0,036	2,4	5,0
M4	0	0,929	0,944	0,977	0,047	3,0	4,0
M4	0,10	0,924	0,944	0,978	0,048	3,2	4,0
M4	0,25	0,905	0,950	0,979	0,050	4,0	3,6

6 lentelė. Atsparumas Gauso triukšmui. FN ir FP yra penkių kartojimų vidurkiai, išskyrus eilutę be triukšmo.

Prie $\sigma = 0,10$ M4 jautrumas sumažėja nuo 0,929 iki 0,924, tai yra vidutiniškai 3,2 klaidingai neigiami vietoj 3. Specifiškumas lieka 0,944. Prie $\sigma = 0,25$ jautrumas yra 0,905 ir vidutiniškai atsiranda ketvirtas klaidingai neigiamas. B1 prie 0,10 nesikeičia, prie 0,25 jautrumas yra 0,943, specifiškumas 0,931. AUC beveik nejuda. Tai reiškia, kad rikiavimas atsparus, o sprendimas prie aukšto jautrumo slenksčio jautresnis triukšmui. Kainų santykio keitimas A7 nėra šio bandymo pakaitalas.


9. Klaidų analizė, sprendimo ribos ir praktinis tinkamumas

7 lentelėje yra visi M4 klaidingai neigiami ir klaidingai teigiami atvejai teste. Tikroji klasė $y_{\text{true}} = 1$ yra piktybinė, 0 yra gerybinė. Slenkstis yra 0,33. Trys FN sudaro 7,1 % piktybinių ir 2,6 % viso testo. Jų tikimybės yra toli žemiau slenksčio, todėl tai nėra vieno šimtosios slenksčio postūmio klausimas.

Tipas	Indeksas	Klasė	p	t
FN	136	1	0,047	0,33
FN	214	1	0,006	0,33

Tipas	Indeksas	Klasė	p	t
FN	298	1	0,004	0,33
FP	82	0	0,801	0,33
FP	158	0	0,594	0,33
FP	209	0	0,381	0,33
FP	497	0	0,448	0,33

7 lentelė. M4 klaidos testavimo aibėje (error_cases.csv).



6 paveikslas. concave_points_worst: mokymo klasių tankis ir trys M4 klaidingai neigiami atvejai.

6 paveiksle trys FN yra tarp 0,07 ir 0,11, ten, kur gerybinių ir piktybinių tankiai persidengia. Patikrinta, kad šių atvejų concave_points_worst yra arčiau gerybinių nei piktybinių mokymo medianos. Tai paaiškina, kodėl tikimybė maža. Nepatikrinta ir todėl neteigiama, kad būtent požymių atranka šiuos tris atvejus nulėmė. Be atrankos FN teste vis tiek yra 3.

Ribos. Imtis yra vieno centro, surinkta praėjusio amžiaus pabaigoje. Išorinės kohortos nėra. Teste tik 42 piktybiniai, todėl vienas atvejis keičia jautrumą apie 2,4 procentinio punkto. Teigiamos prognozės vertė priklauso nuo paplitimo ir į kitą kliniką neperkeliamas. Galutinis testas šiame projekte jau buvo skaičiuotas anksčiau, todėl v3 jo nepateikia kaip naujo nepriklausomo patvirtinimo. Prototipas tinka mokomajam palyginimui, ne diagnostikai.

10. Paleidimas ir atkuriamumas

Aplinka: MATLAB R2026a, Statistics and Machine Learning Toolbox, Deep Learning Toolbox. Sėkla 42 įrašyta config.m. Duomenys, jei jų nėra, parsisiunčiami get_wdbc.m iš UCI. Pilnas pakartojimas nuo nulio, ištrinant models/*.mat ir permokant visus modelius, yra komanda

run_all('clean') projekto šaknyje. Ankstesnis pilnas paleidimas truko apie tris minutes. Iš jau išsaugotų modelių, jų nepermokant, pakanka run_all. Tada perrašomi CSV ir grafikai. Suderinamumo patikra: runtests('tests/test_result_consistency.m').

11. AI naudojimo žurnalas

Žurnalas perkeltas iš projekte jau buvusio reports/ai_usage.md ir papildytas 2026-09-30 patikra. Naujų istorinių užklausų nepridėta. AI tekstas nėra įrodymas. Priimta tik tai, kas sutikrinta su planu, MATLAB išvestimi arba rezultatų lentelėmis.

Priimta bendra realizacijos kryptis: config.m, run_all.m, duomenų, paruošimo, modelių, vertinimo ir predict_case.m moduliai. App Designer langas atmestas, nes plane jis neprivalomas. Nulių concavity ir concave_points eilučių šalinti nepriimta: oficialiame faile nuliai nėra trūkstamos reikšmės, o load_wdbc.m atmeta tik neigiamas reikšmes. Sutapimas, kad t_cost ir t_se98 yra arti vienas kito, nėra programavimo klaida: t_se98 yra paskutinis slenkstis, kurio OOF jautrumas yra bent 0,98.

Atmesta standartizuoti visas 569 eilutes prieš skaidymą. Taip testavimo aibės vidurkis patektų į skalę. fit_scaler.m meta klaidą, kai eilučių yra 569. apply_scaler.m vidurkio iš naujo neskaičiuoja. test_no_leakage.m tikrina, kad scaler.mu sutampa su mokymo vidurkiu. Atmesta ir slenkstį t_se98 rinkti pagal testavimo aibės jautrumą. choose_threshold.m gauna tik OOF tikimybes.

Klaida 1. Pirmame tune_cv.m variante paprastesnė konfigūracija buvo paliekama nelaukiant viso tinklo didžiausio OOF AUC. Tada būtų pasirinktas žemesnis AUC, nei leidžia tinklas. Pataisa: tarp visų konfigūracijų, kurių vidutinis AUC yra ne daugiau kaip 0,002 žemiau už maksimumą, imama paprastesnė. Patikra: peržiūrėtas tune_cv.m ciklas ir konsolės eilutė su geriausiu AUC prieš galutinį testą. Testo metrikos hiperparametrų nekeičia.

Klaida 2. Komentaruose formulių numeriai buvo paimti iš ilgesnio 25 puslapių plano, ne iš koliokviumo trumpojo plano. Pataisa atlikta prieš testo atrakinimą: antraštės sulygintos su koliokviumo formulėmis (z skalė, RBF ir SVM, Platt, slenkstis ir kaina, jautrumas, AUC, Brier). Skaičiai nuo šios klaidos nepriklauso, bet formulės ir kodo ryšys būtų buvęs klaidingas.

Istorinis skaidymo įrašas. Ankstesniame žurnale cvpartition HoldOut 0,20 rezultatas 113/456 buvo priimtas vietoj plano 114/455. Vėlesnė plano redakcija reikalavo 114 testavimo atvejų, 42 piktybinių ir 72 gerybinių. make_split.m tą dydį įrašo prieš mokymą. Senesni modeliai, mokyti 456 eilutėmis, nebenaudojami. Dabartinis test_result_consistency.m patvirtina 455 ir 114.

2026-09-30 patikra, papildanti žurnalą, ne perrašanti senų užklausų. Pirma, ankstesnės abliacijos eilutės su FP = 20 ir FP = 5 neatitinka dabartinio ablation.csv. Dabartinis all30 sutampa su M1: FP = 4, specifiškumas 0,944. Antra, B0 tikimybė nėra mokymo dažnis 170/455. train_majority.m nustato pM = 0, o priorM saugomas, bet nenaudojamas. Brier įvertis 0,368 sutampa su 42/114.

12. Išvados

Duomenų grandinė, atskaitos B0 ir B1 bei metodai M1, M2, M3 ir M4 palyginti tame pačiame 114 atvejų teste. M4, kaip pagrindinis modifikuotas metodas, H1 ir H2 nepatvirtino. Specifiškumas nepadidėjo, atsirado trečias klaidingai neigiamas atvejis, Brier įvertis pablogėjo 0,012. Pagal kainą 5:1 geriausi yra B1 ir M1, kaina 14. Abliacija rodo, kad požymių atranka ir OOF svoriai šioje imtyje nepadidino M4 specifiškumo, palyginti su paprastesniais variantais. Atsparumo bandymas rodo, kad

nedidelis požymių triukšmas M4 jautrumą sumažina nedaug, o stipresnis triukšmas prideda apie vieną klaidingai neigiamą atvejį. Neigiamas H1 rezultatas paliekamas. Prototipas yra B1.

Literatūra

1. Wolberg, W. H., Mangasarian, O. L., Street, N., Street, W. (1993). Breast Cancer Wisconsin (Diagnostic) duomenų rinkinys. UCI Machine Learning Repository. <https://doi.org/10.24432/C5DW2B>
2. Street, W. N., Wolberg, W. H., Mangasarian, O. L. (1993). Nuclear feature extraction for breast tumor diagnosis. Proc. SPIE 1905, 861–870. <https://doi.org/10.1117/12.148698>
3. Rasool, A., Bunternghit, C., Tiejian, L., Islam, Md. R., Qu, Q., Jiang, Q. (2022). Improved machine learning-based predictive models for breast cancer diagnosis. International Journal of Environmental Research and Public Health, 19(6), 3211. <https://doi.org/10.3390/ijerph19063211>
4. Bilal, A., Imran, A., Baig, T. I., Liu, X., Abouel Nasr, E., Long, H. (2024). Breast cancer diagnosis using support vector machine optimized by improved quantum inspired grey wolf optimization. Scientific Reports, 14, 10714. <https://doi.org/10.1038/s41598-024-61322-w>
5. Al Reshan, M. S., Amin, S., Zeb, M. A., Sulaiman, A., Alshahrani, H., Azar, A. T., Shaikh, A. (2023). Enhancing breast cancer detection and classification using advanced multi-model features and ensemble machine learning techniques. Life, 13(10), 2093. <https://doi.org/10.3390/life13102093>
6. Niculescu-Mizil, A., Caruana, R. (2005). Predicting good probabilities with supervised learning. Proceedings of the 22nd International Conference on Machine Learning, 625–632. <https://doi.org/10.1145/1102351.1102430>
7. DeLong, E. R., DeLong, D. M., Clarke-Pearson, D. L. (1988). Comparing the areas under two or more correlated ROC curves: a nonparametric approach. Biometrics, 44(3), 837–845. <https://doi.org/10.2307/2531595>