

INTELEKTUALIOSIOS SISTEMOS

Magistrantūros studijos

KOLOKVIUMO UŽDUOTIS

KRŪTIES NAVIKO POŽYMIŲ KLASIFIKAVIMAS

Sprendimo palaikymo prototipo įgyvendinimo planas

Duomenų rinkinys: UCI Breast Cancer Wisconsin (Diagnostic), WDBC

Parengė: Kamil Skaskevič

Grupė: EKSfm-26

2026 m. rugsėjis

Turinys

Santrauka.....	2
1. Problema, techninis uždavinys ir praktinė vertė	2
1.1. Praktinė problema	2
1.2. Techninis uždavinys.....	2
1.3. Praktinė vertė	2
1.4. Neaiškumai, apribojimai ir klaidų kaina	2
2. Sprendimo etapai: įvestis, išvestis, moduliai	3
3. Atskaitos metodai ir intelektualieji kandidatai	3
3.1. Atskaitos metodai: daugumos klasė ir logistinė regresija.....	3
3.2. M_1 – klasikinis SVM su RBF branduoliu	3
3.3. M_2 – daugiasluoksnis perceptronas.....	3
3.4. M_3 – RBF tinklas	4
3.5. M_4 – modifikuotas ansamblis.....	4
4. Pagrindinis metodas ir patikrinama hipotezė	4
4.1. Kodėl pasirinktas M_4	4
4.2. Hipotezės.....	4
4.3. Gerinimo seka, jei jautrumo riba nepasiekama.....	5
5. Esminės formulės ir sąsaja su moduliais	5
5.1. Standartizacija.....	5
5.2. RBF ir polinominis branduolys.....	5
5.3. Platt kalibracija	5
5.4. Bajeso kainos slenkstis ir empirinė kaina	5
5.5. Svertinis balsavimas pagal tikimybes	5
5.6. Metrikos ir jų klinikinė prasmė.....	6
6. Eksperimento protokolas	6
6.1. Skaidymas ir išankstinis apdorojimas	6
6.2. Duomenų nutekėjimo kontrolinis sąrašas	6
6.3. Hiperparametrai ir statistiniai sprendimai.....	7
6.4. Abliacija ir klaidų analizė	7
6.5. Skaičiavimo biudžetas	7
6.6. Grėsmės išvadų galiojimui.....	7
7. AI naudojimo planas	7
8. Perdavimas programuotojui	8
Literatūra.....	9

Santrauka

Planuojama sprendimo paramos sistema pagal 30 ląstelių branduolių požymių atskirs piktybinius ir gerybinius krūties darinius. Naudojamas viešas UCI WDBC rinkinys (569 atvejai); vaizdai neanalizuojami, o išvestis nėra klinikinė diagnozė. Daroma prielaida, kad praleistas piktybinis atvejis kainuoja penkis kartus daugiau nei perteklinis tyrimas (5 : 1).

Atskaitos metodai yra daugumos klasė B0 ir L2 reguliarizuota logistinė regresija B1. Pagrindinis kandidatas M4 jungia polinominio branduolio atraminių vektorių mašiną (SVM), daugiasluoksnį perceptroną ir logistinę regresiją; jų kalibruotos tikimybės svertinai vidurkinamos. Hipotezė H1: aukšto jautrumo taške M4 testavimo aibėje pasieks bent 0,03 didesnę specifiškumą nei B1, o AUC sumažės ne daugiau kaip 0,005. Modelis parenkamas tik mokymo duomenyse, testavimo aibė įvertinama vieną kartą. Aplinka – MATLAB R2026a.

Žymėjimai: B ir M – gerybinis ir piktybinis atvejis; FN ir FP – klaidingai neigiamas ir klaidingai teigiamas sprendimas; Se ir Sp – jautrumas ir specifiškumas; AUC – plotas po ROC kreive; Brier įvertis – tikimybių paklaida; CV – kryžminė patikra; OOF – prognozė atvejui, nedalyvavusiam ją sukūrusio modelio mokyme.

1. Problema, techninis uždavinys ir praktinė vertė

1.1. Praktinė problema

Sistema vertina 30 plonosios adatos aspiracinės biopsijos (angl. fine-needle aspiration, FNA) ląstelių branduolių geometrinių ir morfologinių požymių: kiekvieno iš dešimties matmenų vidurkį, standartinę paklaidą ir didžiausią reikšmę [1], [2]. Specialistui pateikiama piktybinio atvejo tikimybė ir sprendimas pagal slenkstį, o ne autonominė diagnozė. Darbinis FN ir FP kainų santykis – 5 : 1.

WDBC sudaro 569 atvejai: 357 gerybiniai (62,7 %) ir 212 piktybinių (37,3 %); trūkstamų reikšmių nėra [1]. Su visais 30 požymių klasės tiesiškai atskiriamos, o ankstesniame darbe trijų požymių plokštuma pasiekė apie 97,5 % tikslumą [1]. Vis dėlto maždaug 42 piktybinių atvejų testavimo aibėje vienas FN pakeičia Se apie 2,4 procentinio punkto. Todėl reikia pasikliautinuųjų intervalų ir pakartotinio vertinimo, ne vien taškinio įvertio.

1.2. Techninis uždavinys

Sukurti atkuriamą dvejetainį klasifikatorių ir prototipą. Įvestis – 30 požymių vektorius be paciento identifikatoriaus. Išvestis – piktybiškumo tikimybė, sprendimas, slenkstis, modelio versija ir žymės: `margin_flag`, kai $|p - t| < 0,10$, bei `ood_flag`, kai požymiai išeina už mokymo duomenų ribų. Išvestyje aiškiai nurodoma, kad tai nėra klinikinė diagnozė. Trūkstama, neskaitinė reikšmė arba neteisingas požymių skaičius sustabdo skaičiavimą; klaidos tyliai netaisomos.

B0, B1 ir kandidatai lyginami pagal tą patį skaidymą. Testavimui atidedama 20 % atvejų ($n = 114$; `rng(42)`); aibė atveriamą vienam galutiniam vertinimui tik įrašius modelių kontrolines sumas į `freeze.txt`. Vertinami Se, Sp, AUC ir kalibracija, pateikiant pasikliautinuosius intervalus.

1.3. Praktinė vertė

Vienoda apdorojimo grandinė leidžia sąžiningai palyginti tiesinį, branduolinį, neuronų tinklo ir ansamblio metodus. Keičiant slenkstį matomas kompromisas tarp aptiktų piktybinių ir papildomai tirti siūlomų gerybinių atvejų. Prototipas taip pat pažymi atvejus žmogaus peržiūrai ir rodo tikimybių patikimumą. Klinikinis naudojimas nenumatytas: duomenys yra iš vieno centro, surinkti XX a. paskutiniame dešimtmetyje, išorinės kohortos nėra.

1.4. Neaiškumai, apribojimai ir klaidų kaina

Piktybiškumas patvirtintas histologiškai, gerybiškumas – biopsija arba stebėjimu, tad žymių klaidų dalis nežinoma [2]. Branduolių kontūrai pradėti žymėti ranka; kitų laboratorijų duomenys gali skirtis. Rinkinio 37 % piktybinių atvejų dalis nėra populiacinis paplitimas, todėl PPV ir NPV tiesiogiai į kitą kliniką neperkeliami.

Spindulys, perimetras ir plotas koreliuoja, demografinių duomenų nėra, o tiesinis B1 gali būti labai stiprus. Todėl M4 pranašumo ieškoma aukšto Se taške, ne bendrame tikslume.

Kainų santykis 5 : 1 yra darbinė, ne klinikinė prielaida; tikrinami ir 3 : 1 bei 10 : 1. Gerai kalibruotoms tikimybėms teorinis Bajeso slenkstis $cFP / (cFP + cFN) = 1/6 \approx 0,167$ (6). Praktinis slenkstis dėl galimos kalibracijos paklaidos parenkamas iš OOF prognozių.

2. Sprendimo etapai: įvestis, išvestis, moduliai

Sistema turi penkis etapus (1 lentelė). Testavimo aibė nenaudojama standartizacijai, požymių atrankai, hiperparametrams, svoriams, slenksčiui ar kalibracijai. Aplinka – MATLAB R2026a.

1 lentelė. Penki etapai: moduliai, įvestis, išvestis ir priėmimo taisyklės

Etapas	Moduliai	Įvestis ir išvestis	Priėmimo taisyklė
1. Duomenų gavimas	get_wdbc.m, load_wdbc.m	UCI rinkinys, identifikatorius 17; išvestis – 569×30 matrica ir klasės žymės	212 piktybinių, 357 gerybinių, be trūkstatų reikšmių; identifikatorius pašalintas prieš skaidymą
2. Paruošimas	make_split.m, fit_scaler.m, apply_scaler.m, make_inner_cv.m, select_features.m	Sėkla 42; išvestis – fiksuoti testavimo indeksai, vidurkis ir standartinis nuokrypis iš mokymo duomenų	Stratifikuotas 80/20 skaidymas (~455/~114); atranka tik mokymo skaidinyje
3. Mokymas	tune_cv.m, train_*.m, train_ensemble.m, calibrate_platt.m, choose_threshold.m	Mokymo duomenys ir kainų santykis 5 : 1; išvestis – modeliai, OOF tikimybės, svoriai ir slenksčiai	Hiperparametrai pagal vidutinį OOF AUC; jei skirtumas < 0,002, renkamasi paprastesnį modelį
4. Vertinimas	evaluate_test.m, metrics.m, delong_test.m, brier.m, bootstrap_ci.m, ablation.m, error_analysis.m	Vienas testavimas po freeze.txt; išvestis – lentelės ir paveikslai	Testavimo metrikos negrįžta į parinkimą; H1 nekeičiama
5. Naudojimas	predict_case.m	Vienas 30 požymių atvejis; išvestis – tikimybė, sprendimas, slenkstis, žymės ir atsakomybės tekstas	Tikimybė sutampa su vertinimo modulio; išvestyje nurodoma, kad tai nėra klinikinė diagnozė

3. Atskaitos metodai ir intelektualieji kandidatai

Visi modeliai vertinami vienoda grandine. Rasool ir kt. WDBC rinkinyje nagrinėjo požymių atranką ir polinominį SVM [3], o Al Reshan ir kt. – logistinę regresiją, SVM, daugiasluoksnį perceptroną ir ansamblius [5]. Tai motyvuoja M4, bet nepagrindžia būtent mūsų trijų narių derinio. Publikuotų procentų tiesiogiai nelyginame: skiriasi skaidymai ir patikra, o požymių atrankos izoliavimas ne visur aiškus. Bilal ir kt. [4] remia tik adaptyvios paieškos idėją: jų duomenys – MIAS mamogramos, ne WDBC. Kalibracijai taikoma Platt sigmoidė [6], AUC skirtumui – DeLong testas [7].

3.1. Atskaitos metodai: daugumos klasė ir logistinė regresija

B0 visada renkasi gerybinę klasę: tikslumas apie 0,627, $Se = 0$, $Sp = 1$, $AUC = 0,5$. Tai kontrolė, parodanti, kodėl tikslumo nepakanka. B1 – L2 regularizuota logistinė regresija su klasių svoriais. Ji gražina tikimybę, o regularizacija stabilizuoja koreliuotų požymių koeficientus. Kadangi 30 požymių klasės tiesiškai atskiriamos [1], B1 yra stiprus H1 atskaitos metodas; jo ribotumas – nemodeliuojamos netiesinės sąveikos.

3.2. M₁ – klasikinis SVM su RBF branduoliu

M1 yra minkšto tarpo SVM su spindulinės bazinės funkcijos (RBF) branduoliu (2): bauda C leidžia klaidas, klasių baudos atspindi jų kainą, o branduolys kuria netiesinę ribą. Balas į tikimybę verčiamas Platt sigmoide [6]. Tai klasikinis kurso metodas ir polinominio SVM palyginimas. Rizika – ribotas hiperparametrų tinklulis.

3.3. M₂ – daugiasluoksnis perceptronas

M2 turi vieną paslėptą sluoksnį ir mokomas klaidos skleidimu atgal (LD2). Maždaug 455 mokymo atvejų nepakanka dideliui tinklui, todėl ribojama iki 5–20 neuronų, taikoma L2 regularizacija, ankstyvas stabdymas ir penkių pradinių reikšmių vidurkis. M2 vertinamas atskirai ir kaip M4 narys.

3.4. M₃ – RBF tinklas

M₃ sudaro lokalūs Gauso vienetai (LD3–LD4). Centrai randami k vidurkių metodu, išėjimo svoriai – mažiausių kvadratų būdu. Jei visų vienetų atsakas beveik nulinis, pažymima ood_flag. Standartizacija būtina, nes 30 matmenų erdvėje sunku parinkti pločius. M₃ nėra M₄ narys; ansamblyje naudojamas MLP, nagrinėtas kartu su SVM ir logistine regresija [5].

3.5. M₄ – modifikuotas ansamblis

M₄ sujungia koreliuotų požymių kontrolę [3], polinominio SVM sąveikas ir trijų modelių tikimybes [5]. Tai iš anksto apibrėžta modifikacija, o ne vieno straipsnio atkartojimas. Nariai: polinominio branduolio SVM (laipsnis 2 arba 3), M₂ ir B1. Tikimybės kalibruojamos atskirai [6] ir jungiamos svertiniu balsavimu (8). Svoriai renkami iš OOF prognozių 0,1 žingsniu: mažiausia empirinė kaina (7) tarp variantų, kurių $Se \geq 0,98$. Mokymo skaidinyje iš požymių poros, kai $|Pearsono\ r| > 0,95$, paliekamas labiau su klase susijęs požymis [3]. Jei Se ribos pasiekti nepavyksta, vykdoma 4.3 seka. Rizika – nepastovūs svoriai mažoje imtyje. Saviorganizuojantys žemėlapiai ir konvoliuciniai tinklai šiame plane nesvarstomi, nes įvestis nėra vaizdas ar seka.

2 lentelė. Kandidatai prieš eksperimentą

Metodas	Kas parenkama	Kodėl svarstomas	Pagrindinė rizika
B0 daugumos klasė	Nieko	Kontrolė: tikslumas klaidina	Se = 0
B1 L2 logistinė regresija	Reguliarizacija, klasių svoriai	Stiprus tiesinis atskaitos metodas [1], [3]	Nepagauna sąveikų
M1 SVM su RBF branduoliu	C, mastelis	Klasikinis metodas, palyginimas su polinomu	Per siauras tinklelis
M2 daugiasluksnis perceptronas	Neuronų skaičius, reguliarizacija, pradinė reikšmė	WDBC metodas [5] ir M4 narys	Persimokymas
M3 RBF tinklas	Centrų skaičius, plotis	Kurso metodas, tolimų atvejų žymėjimas	Pločiai 30 matmenų erdvėje
M4 modifikuotas ansamblis	Laipsnis, svoriai, požymių atranka	Jungia [3] ir [5] idėjas	Svorių nepastovumas

4. Pagrindinis metodas ir patikrinama hipotezė

4.1. Kodėl pasirinktas M₄

M₄ leidžia patikrinti, ar [3] siūloma koreliuotų požymių kontrolė ir polinominis branduolys bei [5] nagrinėtas modelių jungimas pranoksta stiprų tiesinį B1. Atskiras MLP jautrus mažai imčiai, RBF tinklas – pločiui; abu lieka palyginime (A6). Jei H1 nepatvirtinama, prototipui naudojamas B1. Neigiamas rezultatas priimtinas; po testavimo modelis nebekeičiamas.

4.2. Hipotezės

Prieš testavimą fiksuojama: stratifikuotas 80/20 skaidymas su rng(42); standartizacija tik mokymo dalyje; hiperparametrai pagal OOF AUC kartotinėje 5×5 CV; svoriai ir slenksčiai tik pagal OOF kalibruotas tikimybes. Viena CV dalis vadinama skaidiniu (angl. fold). Testavimo aibė vertinama vieną kartą.

H1 (pagrindinė). Vidinėje CV parinktame t_{se98} taške $Se \geq 0,98$. Teste M₄ Sp viršija B1 Sp bent 0,03, o AUC sumažėja ne daugiau kaip 0,005.

$$Sp_{M4} - Sp_{LR} \geq 0,03 \quad \text{ir} \quad AUC_{M4} - AUC_{LR} \geq -0,005. \quad (H_1)$$

Sp sąlygai reikia bent 0,03 taškinio skirtumo ir teigiamos suporuoto 2000 kartų atkartojimo (bootstrap) 95 % intervalo apatinės ribos. AUC skirtumo 95 % intervalo apatinė riba pagal porinį DeLong metodą [7] turi būti $\geq -0,005$. 0,03 atitinka maždaug du FP mažiau iš ~72 gerybinių testavimo atvejų. H1 tikėtinesnė, jei dydžio ir formos sąveikos svarbios, o nariai klysta skirtingai; jei tiesinis atskyrimas pakankamas [1], prieaugio gali nebūti.

H2 (kalibracija). M4 Brier įvertis bus ne daugiau kaip 0,01 didesnis už B1 įvertį, o kalibracijos nuolydis bus 0,8–1,25. Jei H1 patvirtinama, bet H2 ne, sprendimas lieka iš M4, tačiau jo tikimybė rodoma su įspėjimu arba pakeičiama B1 tikimybe.

H3 (stabilumas). Įdėtinėje CV (10 kartų po 5 išorinius skaidinius) M4 Sp prieaugis, kai $Se \geq 0,98$, bus teigiamas bent 70 % skaidinių. Tai papildomas stabilumo, ne H1 sprendimo, patikrinimas.

Hipotezės ir slenksčių taisyklės prieš testavimą įrašomos į reports/preregistration.md, jo kontrolinė suma – į freeze.txt.

4.3. Gerinimo seka, jei jauktumo riba nepasiekama

Jei mokymo dalies OOF $Se < 0,98$, tik mokymo duomenyse taikomi trys iš anksto numatyti žingsniai: 1. Derinamos SVM bauda C ir LR bei tinklo klasių svoriai aplink 5 : 1 santykį, kol pasiekama riba arba baigiasi tinktelis. 2. Pagal [3] iš porų, kurių |Pearsono r| > 0,95, paliekamas su klase labiau susijęs požymis; silpniausiai susiję požymiai šalinami, modeliai mokomi iš naujo. 3. Tik pagal OOF prognozes parenkamas mažiausios empirinės kainos (7) slenkstis iš tų, kurių $Se \geq 0,98$ (t_{se98}). Jei tokių nėra, pasirenkamas didžiausio OOF Se slenkstis ir pažymima, kad riba nepasiekta. Jei Se vis tiek < 0,98, tai užregistruojama, o H1 teste vertinama vieną kartą. Neigiamo H1 atveju seka nekartojama ir pasirenkamas B1.

5. Esminės formulės ir sąsaja su moduliais

Toliau $i = 1 \dots n$ žymi mokymo objektą, z_i – standartizuotą 30 matmenų vektorių; SVM formulėse piktybinė klasė yra +1, gerybinė –1. Modulių sąsaja pateikta 3 lentelėje.

5.1. Standartizacija

Skirtingo mastelio požymiai standartizuojami. CV metu μ_j ir σ_j skaičiuojami tik to skaidinio mokymo dalyje, ne tikrinimo ar galutinio testavimo aibėje.

$$z_{ij} = (x_{ij} - \mu_j) / \sigma_j, \quad \mu_j \text{ ir } \sigma_j \text{ skaičiuojami tik mokymo indeksams } Tr \quad (1)$$

5.2. RBF ir polinominis branduolys

M1 taiko RBF, o M4 SVM narys – polinominį branduolį. Čia s – mastelis, d – laipsnis, S – atraminių vektorių, kurių $\alpha_i \neq 0$, aibė; (4) yra sprendimo funkcija.

$$K_{RBF}(\mathbf{z}, \mathbf{z}') = \exp(-\|\mathbf{z} - \mathbf{z}'\|^2 / s^2), \quad \gamma = 1/s^2 \quad (2)$$

$$K_{poly}(\mathbf{z}, \mathbf{z}') = (\gamma \mathbf{z} \cdot \mathbf{z}' + r)^d, \quad d \in \{2, 3\}, \quad r = 1 \quad (3)$$

$$f(\mathbf{z}) = \sum_{i \in S} \alpha_i y_i K(\mathbf{z}_i, \mathbf{z}) + b \quad (4)$$

5.3. Platt kalibracija

SVM balas paverčiamas tikimybe. A ir B mokomi iš OOF balų [6]. Tobulo atskyrimo atveju taikiniai atitraukiami nuo 0 ir 1; testavimo balai kalibracijai nenaudojami.

$$P(M | \mathbf{z}) = 1 / (1 + \exp(A f(\mathbf{z}) + B)) \quad (5)$$

5.4. Bajeso kainos slenkstis ir empirinė kaina

Esant nevienodai klaidų kainai 0,5 slenkstis netinka. Teorinis (6) galioja gerai kalibruotoms tikimybėms. Iš OOF prognozių parenkami t_{cost} (mažiausia kaina, 5 : 1), t_{se98} (didžiausias slenkstis su OOF $Se \geq 0,98$) ir tik papildomam palyginimui t_{Youden} (didžiausias $Se + Sp - 1$).

$$t^* = C_{FP} / (C_{FP} + C_{FN}) = 1/6 \approx 0,167 \quad (6)$$

$$EC(t) = C_{FN} \cdot FN(t) + C_{FP} \cdot FP(t), \quad t_{cost} = \arg \min_t EC(t) \quad (7)$$

5.5. Svertinis balsavimas pagal tikimybes

M4 vidurkina atskirai kalibruotas narių tikimybes. Svariai renkami tik iš OOF prognozių; lygių svorių variantas – abliacijos kontrolė.

$$p_4(\mathbf{z}) = \sum_k w_k p_k(\mathbf{z}) / \sum_k w_k, \quad k \in \{SVM_{poly}, MLP, LR\}, \quad w_k \geq 0 \quad (8)$$

5.6. Metrikos ir jų klinikinė prasmė

Se matuoja aptiktus piktybinius, Sp – teisingai atpažintus gerybinius atvejus. Todėl pirmiausia reikalaujama didelio Se, tada lyginamas Sp; vien tikslumas klaidina. PPV ir NPV priklauso nuo paplitimo, tad rinkinio 37 % piktybinių atvejų daliai apskaičiuotos vertės kitur tiesiogiai netinka. AUC (10) vertina rikiavimą visais slenksčiais, bet ne konkretų aukšto Se tašką. Brier įvertis (11) matuoja tikimybių paklaidą, (12) – porinio DeLong palyginimo statistiką [7].

$$Se = TP/(TP+FN), Sp = TN/(TN+FP), PPV = TP/(TP+FP), NPV = TN/(TN+FN) \quad (9)$$

$$AUC = P(f(\mathbf{z}_M) > f(\mathbf{z}_B)) \quad (10)$$

$$BS = (1/m) \sum_{k=1}^m (p_k - y_k)^2 \quad (11)$$

$$Z = (\hat{\theta}_1 - \hat{\theta}_2 - \delta_0) / \sqrt{(\hat{v}_1 + \hat{v}_2 - 2\hat{c}_{12})}, \delta_0 = -0,005 \quad (12)$$

3 lentelė. Formulų kintamųjų sąsaja su moduliais

Formulė	Kintamieji	Modulis	Kur fiksuojama
(1)	Vidurkis, standartinis nuokrypis	fit_scaler.m, apply_scaler.m	Tik mokymo indeksai
(2)	C, mastelis s	train_svm_rbf.m	cfg.svm
(3)–(4)	Laipsnis d, koeficientai α_i	train_svm_poly.m	cfg.svm.polyOrder, kainų matrica
(5)	A, B	calibrate_platt.m	5 OOF skaidiniai
(6)–(7)	Slenkstis, klaidų kainos	choose_threshold.m	5 : 1, Se tikslas 0,98
(8)	Svoriai w_k	train_ensemble.m	Žingsnis 0,1
Požymių atranka	Pearsono koreliacija	select_features.m	Riba 0,95; tik mokymo skaidinys
(9)–(12)	Se, Sp, AUC, Brier įvertis	metrics.m, delong_test.m, brier.m, bootstrap_ci.m	2000 atkartojimų

6. Eksperimento protokolas

6.1. Skaidymas ir išankstinis apdorojimas

569 atvejai stratifikuotai skaidomi: 20 % testui ($n = 114$; ~42 piktybiniai ir ~72 gerybiniai), ~455 mokymui. Indeksai saugomi split_idx.mat, sėkla rng(42). Mokymo dalyje vykdoma 5 skaidinių CV, kartojama 5 kartus. Prieš mokymą šalinamas identifikatorius, piktybinė klasė koduojama 1, tikrinama 569×30 matrica ir reikšmių pilnumas. Standartizuojama pagal (1); trūkstamos reikšmės nepildomos, išskirtys pagal visą rinkinį nešalinamos, požymiai pagal testą neatrenkami.

6.2. Duomenų nutekėjimo kontrolinis sąrašas

Visi 4 lentelės punktai tikrinami prieš vienintelį galutinį testą.

4 lentelė. Duomenų nutekėjimo kontrolinis sąrašas

Punktas	Taisyklė	Kur tikrinama
Standartizacija	μ ir σ tik iš mokymo duomenų; CV metu – tik iš skaidinio mokymo dalies	fit_scaler.m, test_no_leakage.m
Požymių atranka	Koreliacija tik mokymo skaidinyje; palikti požymiai saugomi su modeliu	select_features.m
Hiperparametrai, svoriai, slenkstis ir kalibracija	Parinkami tik iš OOF; testavimo metrikos negrįžta į mokymą	choose_threshold.m, train_ensemble.m
Testavimo aibė	20 %, $n = 114$, sėkla 42; vienas galutinis įvertinimas, be pakartotinio slenksčio parinkimo	make_split.m, evaluate_test.m
Gerinio seka	Tik kai OOF Se < 0,98; po testo nekartojama	reports/preregistration.md

6.3. Hiperparametrai ir statistiniai sprendimai

Pradinės reikšmės pateiktos 8 lentelėje, visas tinklelis – config.m. Renkamasi didžiausią vidutinį OOF AUC turinčią konfigūraciją; jei skirtumas $< 0,002$, imama paprastesnė. Modelis permokomas visoje mokymo dalyje, o kalibracija, svoriai ir slenkstis lieka parinkti pagal OOF. Jei $Se < 0,98$, taikoma 4.3 seka. Pirminės metrikos – Se, Sp, AUC ir kalibracija; kitoms teikiama intervalai be papildomų hipotezių.

6.4. Abliacija ir klaidų analizė

Visoms abliacijoms naudojami tie patys skaidymo indeksai; jos H1 sprendimo nekeičia.

Po testavimo visiems FN ir FP saugomi požymiai, tikimybė ir atstumas iki slenkščio. FN lyginami su klasių medianomis, ypač pagal concave_points_worst ir area_worst [2]; klaidų sutapimo matrica rodo, ar modeliai klysta dėl tų pačių atvejų. Teigiamas margin_flag arba ood_flag reiškia žmogaus peržiūrą.

5 lentelė. Abliacijos planas

ID	Kas keičiama	Klausimas	Metrika
A0	Daugumos klasė	Ar metrikos skaičiuojamos teisingai?	$Se = 0$, $Sp = 1$, $AUC = 0,5$
A1	LR be klasių svorių ir su jais	Kaip kaina keičia Se?	Se, Sp, Brier įvertis
A2	Tiesinis, RBF ir polinominis SVM	Ar polinomas naudingas šiame protokole?	Sp prie $Se \geq 0,98$, AUC
A3	Be Platt kalibracijos ir su ja	Ar mažėja Brier įvertis, nesikeičiant AUC?	Brier įvertis, nuolydis
A4	Be logaritminės transformacijos ir su ja	Ar ji stabilizuoja LR?	AUC, Brier įvertis
A5	Visi 30 požymių, tik didžiausios reikšmės arba atranka pagal [3]	Ar susijusių požymių šalinimas mažina FN?	AUC, Sp prie $Se \geq 0,98$
A6	MLP, RBF tinklas, M4 ir LR	Ar M4 geresnis už atskirus metodus?	Sp prie $Se \geq 0,98$, Brier įvertis
A7	Kainos 1 : 1, 3 : 1, 5 : 1, 10 : 1	Kaip keičiasi slenkstis?	Empirinė kaina, Se, Sp
A9	Lygūs ir pagal kainą parinkti svoriai	Ar svoriai didina Sp aukšto Se taške?	Sp prie $Se \geq 0,98$

6.5. Skaičiavimo biudžetas

Pakanka nešiojamojo kompiuterio CPU: tinkleliai ~30 min., svoriai ~1 min., abliacijos ~35 min., H3 ~50 min.; iš viso iki 3 val., žmogaus darbas ~5 dienos. Trūkstant laiko mažinamas polinomo mastelių skaičius, bet ne testavimo aibė ar H1 atkartojimų skaičius.

6.6. Grėsmės išvadų galiojimui

6 lentelė. Grėsmės išvadų galiojimui ir numatytos priemonės

Grėsmė	Poveikis	Priemonė
Maža testavimo aibė (~42 piktybiniai, ~72 gerybiniai)	Vienas atvejis pakeičia Se ~2,4 procentinio punkto	Intervalai, DeLong [7], atkartojimas ir H3; vieno atvejo skirtumas atskirai neinterpretuojamas
Jau stiprus tiesinis modelis [1]	H1 gali nepasitvirtinti	Iš anksto numatytas B1 kaip atsarginis modelis; neigiama išvada priimtina
Nutekėjimas per standartizaciją, atranką, svorius ar slenkstį	Optimistiniai, neatkartojami įverčiai	4 lentelė, test_no_leakage.m, freeze.txt
Svetimų skaičių perkėlimas	[3], [5] procentai nėra šio plano rezultatai; [4] tiria MIAS, ne WDBC	Literatūros rezultatų nelyginti su būsimu testu; [4] tikslumo skaičių neperkelti

7. AI naudojimo planas

AI naudojamas tik tekstui, kodo karkasui ir testų scenarijams rengti, ne kaip šaltinis ar rezultatų vertintojas. Už šaltinius, kodą ir išvadas atsako studentas.

7 lentelė. AI naudojimas ir tikrinimas

Veikla	Kam naudojama	Kaip tikrinama
Citatos ir literatūra	Šaltinių sąrašo juodraštis	DOI atveriami per doi.org ir sutikrinami su Crossref (autoriai, metai, leidinys); WDBC 569×30 atskiriamas nuo WBCD 699×9 ; [4] citation_log.csv žymimas kaip MIAS šaltinis; šaltinis be DOI atmetamas
Formulės	Užrašymas, skaitinė patikra	(5) lyginama su [6], (12) – su [7]; (4) atkurama iš koeficientų ir lyginama su MATLAB išvestimi
MATLAB kodas	Karkasas ir testai	Pagal 4 lentelę tikrinama duomenų izoliacija, sėklos ir dviejų paleidimų sutapimas; AI sugeneruota ir ranka taisyta dalis žymima ai_code_review.md
Rezultatų interpretavimas	Lentelių teksto juodraštis	Skaičiai į atskaitą imami tik iš automatiškai sugeneruotų CSV; AI jų nekuria, netaiso ir nekeičia interpretuodamas; H1 ir H2 po testo nekeičiamos

Šio plano DOI 2026-09-29 sutikrinti per Crossref. Rinkinio dydis, 569 atvejai ir 30 požymių, patvirtintas pagal wdbc.names.

8. Perdavimas programuotojui

Projektą sudaro config.m, run_all.m ir katalogai data, prep, models, evalx, app, tests, reports. Šioje redakcijoje pridėti select_features.m, train_svm_poly.m ir train_ensemble.m.

Pilnas konfigūracijas saugo config.m. Paleidimo tvarka: patikrinti 569×30 duomenis ir 357/212 klasių pasiskirstymą; fiksuoti skaidymą ir paleisti testus; užregistruoti hipotezes; mokyti modelius ir, tik jei OOF Se < 0,98, vykdyti 4.3 seką; atlikti vieną galutinį testavimą; tada H3 ir vieno atvejo prototipą. Darbas baigtas, kai testai praeina, du paleidimai sutampa, o prototipas grąžina tikimybę, sprendimą ir nurodo, kad tai nėra diagnozė.

8 lentelė. Pagrindiniai eksperimento parametrai

Parametrų grupė	Pradinės reikšmės	Paskirtis
Atkuriamumas	Sėkla 42; testas 0,20	Fiksuotas stratifikuotas skaidymas
Vidinė patikra	5 skaidiniai $\times$ 5 kartojimai	Hiperparametrai ir OOF prognozės
Klaidų kaina	c_FN : c_FP = 5 : 1; Se tikslas 0,98	Aukšto jautrumo taškas
Logistinė regresija	$\lambda \in \{1e-4, 1e-3, 1e-2, 1e-1, 1\}$	Regularizacijos paieška
SVM su RBF branduoliu	$C \in \{0,1; 0,3; 1; 3; 10; 30; 100\}$; $s \in \{1; 2; 3; 5; 8; 12; 20\}$	Klasikinio SVM palyginimas
Polinominis SVM	$d \in \{2; 3\}$; mastelis $\in \{0,5; 1; 2; 4\}$	M4 polinominio nario paieška
Daugiasluksnis perceptronas	$H \in \{5; 10; 20\}$; $\lambda \in \{0; 0,1; 0,3\}$; 5 pradinės reikšmės	Persimokymo kontrolė
Ansamblis	Polinominis SVM, MLP, LR; svorių žingsnis 0,1	M4 tikimybių jungimas
Vertinimas	2000 atkartojimų; H3 5×10	Intervalai ir stabilumas

Pilnos parametrų reikšmės bus saugomos config.m, o dokumente pateikiami tik tie nustatymai, kurie reikalingi eksperimento logikai suprasti.

Paleidimo tvarka yra tokia. Pirmiausia duomenys įkeliami ir patikrinama, kad yra 569 atvejai, 30 požymių, 357 gerybiniai ir 212 piktybinių. Tada fiksuojamas skaidymas ir paleidžiami testai. Įrašomos hipotezės. Mokomi visi modeliai, o 4.3 seka taikoma tik jei OOF jautrumas mažesnis už 0,98. Po to atliekamas vienas galutinis įvertinimas, tada H3 ir vieno atvejo prototipas. Darbas baigtas, kai testai praeina, du paleidimai sutampa, o prototipas grąžina tikimybę, sprendimą ir tekstą, kad tai nėra diagnozė.FV

Literatūra

- [1] Wolberg, W. H., Mangasarian, O. L., Street, N., Street, W. (1993). Breast Cancer Wisconsin (Diagnostic) [duomenų rinkinys]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5DW2B>
- [2] Street, W. N., Wolberg, W. H., Mangasarian, O. L. (1993). Nuclear feature extraction for breast tumor diagnosis. *Proc. SPIE* 1905, 861–870. <https://doi.org/10.1117/12.148698>
- [3] Rasool, A., Bunternghit, C., Tiejian, L., Islam, Md. R., Qu, Q., Jiang, Q. (2022). Improved machine learning-based predictive models for breast cancer diagnosis. *International Journal of Environmental Research and Public Health*, 19(6), 3211. <https://doi.org/10.3390/ijerph19063211>
- [4] Bilal, A., Imran, A., Baig, T. I., Liu, X., Abouel Nasr, E., Long, H. (2024). Breast cancer diagnosis using support vector machine optimized by improved quantum inspired grey wolf optimization. *Scientific Reports*, 14, 10714. <https://doi.org/10.1038/s41598-024-61322-w>
- [5] Al Reshan, M. S., Amin, S., Zeb, M. A., Sulaiman, A., Alshahrani, H., Azar, A. T., Shaikh, A. (2023). Enhancing breast cancer detection and classification using advanced multi-model features and ensemble machine learning techniques. *Life*, 13(10), 2093. <https://doi.org/10.3390/life13102093>
- [6] Niculescu-Mizil, A., Caruana, R. (2005). Predicting good probabilities with supervised learning. *Proceedings of the 22nd International Conference on Machine Learning*, 625–632. <https://doi.org/10.1145/1102351.1102430>
- [7] DeLong, E. R., DeLong, D. M., Clarke-Pearson, D. L. (1988). Comparing the areas under two or more correlated ROC curves: a nonparametric approach. *Biometrics*, 44(3), 837–845. <https://doi.org/10.2307/2531595>